




Structuration et Analyse des Données Produits & Stocks




Analyses Exploratoires des Données

- *Datasets*

Nous avons 3 datasets:


- ERP
- WEB
- Table de liaison



Analyses Exploratoires des Données

- *Les erreurs du fichier erp*

- **2 “stock quantity ” négatifs**
- **4 erreurs** dans la colonne “stock status”
- **3 valeurs incohérentes** dans la colonne “price”




Analyses Exploratoires des Données

- *Les erreurs du fichier erp*


	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	stock_status_2
4	4039	1	46.0	3	outofstock	23.77	instock
398	4885	1	18.7	0	instock	9.66	outofstock
449	4973	0	10.0	-10	outofstock	4.96	instock
573	5700	1	44.5	-1	outofstock	22.30	instock

Prix minimum : -20.0

Prix maximum : 225.0




	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	stock_status_2
151	4233	0	-20.0	0	outofstock	10.33	outofstock
469	5017	0	-8.0	0	outofstock	4.34	outofstock
739	6594	0	-9.1	19	instock	4.61	instock



Analyses Exploratoires des Données

- *Les erreurs du fichier web*

- **83 lignes entièrement vides**
- **2 erreurs dans la colonne 'total_sales'**
avec des valeurs négatives
- **2 erreurs avec des sku manquants**
- **2 sku non conformes** avec '13127-1' et
'bon-cadeau-25-euros' dupliqué
- **714 sku en doublons**



Analyses Exploratoires des Données

- *Les erreurs du fichier web*

	sku	total_sales	post_author	post_date	post_date_gmt	product_type	post_title	post_excerpt	post_name	post_modified	post_modified_gmt
84	NaN	-56.0	2.0	2018-08-08 11:23:43	2018-08-08 09:23:43	Vin	Pierre Jean Villa Condrieu Jardin Suspendu 2018	Le nez séduit par ses parf...	pierre-jean-villa-condrieu-suspendu-2018	2019-11-02 13:24:01	2019-11-02 12:24:01
87	NaN	-17.0	2.0	2018-07-31 12:07:23	2018-07-31 10:07:23	Vin	Pierre Jean Villa Côte Rôtie Fongéant 2017	Fongéant 2017 explose sur un fruit brillant, p...	pierre-jean-villa-cote-rotie-fongéant-2017	2019-11-02 13:24:15	2019-11-02 12:24:15


Valeurs sku non conformes:

272	13127-1
842	bon-cadeau-25-euros
1084	sku_null1
1087	sku_null2
1117	13127-1
1387	bon-cadeau-25-euros

[60]:

	sku	total_sales	post_author	post_date	post_date_gmt	product_type	post_title	post_excerpt	post_name	post_modified	post_modified_gmt	guid	post_type
8	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN
20	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN
30	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN
37	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN
41	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN
...	...	...	...	...	...	...	...	...	...	...	...	...	...
1384	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN
1429	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN
1432	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN
1445	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN
1457	NaN	NaN	NaN	NaT	NaT	NaN	NaN	NaN	NaN	NaT	NaT	NaN	NaN

83 rows x 13 columns



Analyses Exploratoires des Données


- Les erreurs du fichier liaison

- 90 doublons dans la colonne “id_web”



Nettoyage de données


- Exemples de nettoyage effectués



- **Suppression des colonnes inutiles**
- **Suppression des lignes vides** (nan)
- **Suppression des doublons**

- **Changement du types des colonnes:**
id_web (int) , stock_status(category)

- **Remplacement des valeurs négatives** dans:
“total_sales” par NaN



Fusion ou consolidations des données


```
#Fusion des fichiers df_erp et df_liaison  
df_merge = pd.merge(df_erp, df_liaison, on='product_id', how='inner')
```

```
#Changement du nom de colonne : 'sku' devient 'id_web' dans df_web  
df_web = df_web.rename(columns={'sku': 'id_web'})
```

```
#Fusion des datasets df_merge et df_web  
df_merge = pd.merge(df_merge, df_web, on='id_web', how='inner')
```

Utilisation des clefs:

- “product id” => fusion de df_erp et liaison
- “id_web” => df_merge et df_web




Fusion ou consolidations des données

Nombre total d'articles dans df_merge : 712

Nombre d'articles sans correspondance : 90

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
49	4090	0	73.0	0	outofstock	33.79
50	4092	0	47.0	0	outofstock	25.25
119	4195	0	14.1	0	outofstock	7.36
131	4209	0	73.5	0	outofstock	33.01



Jonction du fichier df_merge et df_web

- 90 articles sans correspondances

**Articles plus en vente sur le
site web?**

CA

- **CA total du site:**

Chiffre d'affaires total du site : 150 752€

- **La loi de Pareto 80/20 en CA**

Nombre d'articles représentant 80% du CA : 415
Proportion dans le catalogue : 58.37%


- **Z score**

Le seuil de prix avec un z-score > 3 est de: 116.40€

Le seuil de **116,40€** est donc la valeur à partir de laquelle un prix est considéré comme un **outlier** (anomalie)

TOP 20 articles par CA

Top 20 articles par chiffre d'affaires



Analyses univariées du prix

- ***L'écart interquartile***

```
: #Définissez un seuil pour les articles "outliers" en prix
# Récupération des quartiles pour la colonne "price"
Q1 = df_merge['price'].quantile(0.25)
Q3 = df_merge['price'].quantile(0.75)
IQR = Q3 - Q1

# Définition du seuil
seuil_haut = Q3 + 1.5 * IQR


print(f"Seuil haut : {seuil_haut:.2f}")

Seuil haut : 84.00
```




[319]:	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	id_web	total_sales	post_author	post_date	...	z_score_price	ca_par_article	pa
147	4352	1	225	0	outofstock	137.81	15940	11	2.0	2018-03-02 10:30:04	...	6.974126	2475	
325	5026	1	86	101	instock	50.13	13913	9	2.0	2018-07-18 10:46:30	...	1.955223	774	
436	4359	1	85	112	instock	51.93	13853	7	2.0	2018-03-02 11:11:48	...	1.919116	595	
453	5008	1	105	12	instock	56.42	11602	7	2.0	2018-07-17 10:52:41	...	2.641261	735	
454	6212	1	115	16	instock	59.42	13996	7	2.0	2019-07-25 09:09:17	...	3.002333	805	

répartition des prix




- **Prix minimum** : 5 €
- **1er quartile (Q1)** : 14 €
- **Médiane** : 23 € → 50 % des articles coûtent moins de 23 €
- **3e quartile (Q3)** : 42 €
- **Prix maximum (hors valeurs extrêmes)** : 83 € (upper fence)
- **Valeurs extrêmes (outliers)** : plusieurs articles dépassent 83 €, jusqu'à un maximum de 225 €
- **La majorité des prix se situent donc entre 14 € et 42 €**

Taux de marge moyen par type de produit



TOP 20 des articles avec le plus de mois de stock

Top 20 des articles avec le plus de mois de stock



Quantité

- ***La loi de Pareto 80/20 en quantité***

Nombre total d'articles dans le catalogue : 711

Nombre d'articles représentant 80% des quantités vendues : 423

Proportion dans le catalogue : 59.49%

Quantité totale vendue par ces articles : 4854

- **423 articles génèrent 80 %** du volume des ventes
- Ils représentent **environ 60 % du catalogue total**
- **Une part importante du catalogue contribue donc faiblement aux ventes totales**

Top 20 des articles par quantités vendues



Heatmap des corrélations entre stock, sales et price



Actions pour la suite

df_web

- **Suppression** des colonnes inutiles
- **Mettre à jour** les produits
- Corriger les id manquants
- Mettre les colonnes au bon format

df_liaison

- Mettre à jour les clefs régulièrement

Actions pour la suite

- Remonter les anomalies** dès que possible
- Attention aux erreurs de saisies**
- Corriger les produits** avec **des prix incohérents par rapport au prix d'achat**
- Eviter les doublons**

Attention aux méthodes d'analyse

Méthodes statistiques employés

- *La loi de Pareto (80/20)*
- *Le Z-score*
- *L'écart interquartile*

Utile pour : *identifier les produits les plus performants, détecter les valeurs aberrantes et analyser la dispersion des données.*

Limites éventuelles de l'analyse

Ces outils présentent **certaines limites**. Des méthodes comme **le Z-score étant sensibles aux valeurs extrêmes ou absentes**, les indicateurs calculés peuvent être biaisés. Il est donc nécessaire de nettoyer et de compléter les données avant de tirer des conclusions solides

MERCI!

